Informe de descripción del sistema:

111908 - Estimación de la capacidad de generación de energía eléctrica del agua coproducida en campos de petróleo y gas en Colombia a partir de técnicas de aprendizaje automático informado por la física.

Nombre: Carlos Andrés Pérez Aguirre

Contrato de servicios: 6368 de 2025

Grupo de investigación en Automática

19 de marzo de 2026

Índice

1. Base de datos inicial consolidada y documentada. 3

2. Paradigma Arquitectónico: Modularidad y Bajo Acoplamiento 3
2.1. Componentes Principales . . . 3
2.1.1. Módulo 1: Adquisición de Datos (Scraper) . . . 3
2.1.2. Módulo 2: Procesamiento y Análisis Inteligente (Processor) . . . 4
2.1.3. Módulo 3: Ingesta y Publicación (*Uploader*) . . . 4

3. Flujo de Trabajo Integrado 5
3.1. Fase 1: Adquisición y Persistencia . . . 5
3.2. Fase 2: Filtrado y Enriquecimiento Semántico . . . 5
3.3. Fase 3: Ingesta y Publicación . . . 5

4. Arquitectura de Componentes de Software 7
4.1. Módulo 1: DatabaseManager y Network Wrapper . . . 7
4.2. Módulo 2: *SubmissionContext* y *FileHandler* . . . 7
4.3. Módulo 3: CKAN API Wrapper . . . 7

5. Integración de Modelos de Lenguaje Generativo con Validación Semántica 8

6. Garantías de Calidad de Datos 8

7. Manejo de Excepciones y Recuperación ante Fallos 8

8. Implicaciones para la Transición Energética Nacional 9

9. Conclusión 9

10. Visualización y Acceso a Datos en la Plataforma CKAN 9
10.1. Búsqueda y Descubrimiento de Datasets . . . 9
10.2. Metadatos Enriquecidos y Variables Identificadas . . . 10
10.3. Gestión de Recursos y Proveniencia . . . 11
10.4. Verificación y Consumo del Dato Tabular . . . 12
10.5. Base de datos SQL . . . 13

11. Revisión sistemática automatica 14
11.1. Propósito general . . . 15
11.2. Identificación de fuentes y extracción . . . 15
11.3. Análisis asistido por inteligencia artificial . . . 15
11.4. Consolidación en repositorio centralizado . . . 15
11.5. Trazabilidad y reproducibilidad . . . 15
11.6. Aplicabilidad al dominio geológico . . . 16

1. Base de datos inicial consolidada y documentada.

La estimación del potencial geotérmico de recursos coproducidos en campos de petróleo y gas colombianos requiere la integración sistemática de datos heterogéneos provenientes de múltiples disciplinas científicas. Este proceso implica no solo la recopilación masiva de información, sino también su validación semántica y catalogación conforme a estándares de calidad aceptables para la comunidad científica. El presente capítulo describe el Sistema Automatizado de Recuperación, Análisis y Divulgación de Datos (SARAD), una solución técnica diseñada para automatizar cada etapa del ciclo de vida de estos datos, desde su extracción de repositorios públicos hasta su publicación en plataformas de acceso abierto.

La arquitectura de SARAD integra tres componentes modulares independientes—adquisición, procesamiento cognitivo e ingesta—que se comunican mediante artefactos de datos persistentes. Este diseño garantiza robustez operacional, escalabilidad horizontal, y recuperación automática ante fallos parciales. Además, el sistema incorpora un modelo de lenguaje local (LLM) para enriquecer semánticamente los datos mediante la extracción de metadatos y validación de viabilidad técnica conforme a criterios de ingeniería específicos para sistemas de Ciclo Orgánico de Rankine (ORC).

2. Paradigma Arquitectónico: Modularidad y Bajo Acoplamiento

SARAD adopta un paradigma arquitectónico basado en la separación de responsabilidades, donde cada módulo operativo ejecuta un conjunto bien definido de transformaciones sobre los datos sin dependencias directas del estado o la implementación interna de otros módulos [Chu, 2024; Cuello, 2024]. Esta aproximación modular ofrece ventajas operacionales significativas:

1. **Independencia de despliegue:** Cada módulo puede actualizarse, escalarse o reemplazarse sin afectar los demás.
2. **Recuperación ante fallos:** La persistencia de estados intermedios en archivos `JSON` permite que el sistema reanude el procesamiento desde el último punto exitoso.
3. **Testabilidad:** Las interfaces claramente definidas facilitan la validación unitaria y de integración.
4. **Escalabilidad:** Los componentes pueden ejecutarse en paralelo o distribuirse en múltiples máquinas sin modificación del código.

2.1. Componentes Principales

SARAD se estructura en tres módulos funcionales distintos:

2.1.1. Módulo 1: Adquisición de Datos (Scraper)

Este componente implementa la lógica de extracción web (*web scraping*) con énfasis en robustez y trazabilidad. El módulo gestiona:

Base de Datos Local Idempotente. Se mantiene una base de datos documental ligera (usando la libreria `TinyDB`) que registra el estado de cada identificador de envío procesado. Antes de iniciar una descarga, el sistema consulta este registro. Si el identificador ya está marcado como "*complete*", se omite el procesamiento, optimizando ancho de banda y tiempo de ejecución [Chu, 2024]. Esta estrategia de idempotencia es crítica en sistemas de ingesta masiva de datos, donde las reintentativas accidentales pueden generar duplicidad y consumo innecesario de recursos.

Resiliencia de Red. El módulo implementa reintentos automáticos con espera exponencial ante fallos de conexión o respuestas HTTP 5xx. Los errores HTTP 404 (recurso no encontrado) se registran en auditoría sin detener la ejecución del lote completo, garantizando un comportamiento *fail-safe* [Gupta, 2025; Yudin, 2025].

Extracción Polimórfica de Metadatos. El módulo es capaz de parsear código `HTML` y bloques `JSON-LD`(*JavaScript Object Notation for Linked Data*, es un formato de datos liviano y legible para humanos que se utiliza para estructurar datos en la web) para extraer metadatos básicos (título, descripción, autores). En aquellos repositorios que lo permitan, identifica y extrae citas bibliográficas en formato BibTeX.

2.1.2. Módulo 2: Procesamiento y Análisis Inteligente (Processor)

Este es el núcleo lógico de SARAD, donde ocurre el enriquecimiento semántico y la validación de viabilidad técnica. El módulo:

Filtrado Determinista de Formato. Antes de incurrir en el costo computacional del análisis de inteligencia artificial, el sistema aplica un filtro binario: ¿contiene el envío archivos de datos tabulares (CSV, XLSX, Parquet) o estructuras comprimidas con tales formatos en su interior? Si la respuesta es negativa, el envío se marca como "skipped" y se descarta, ahorrando recursos. Este paso es determinante para la eficiencia general del pipeline [Maddali, 2021].

Extracción Polimórfica de Contenido. El sistema implementa estrategias diferenciadas según el tipo de archivo. Para documentos (PDF, DOCX), extrae texto legible de las primeras y últimas páginas. Para tablas (CSV, Excel), genera resúmenes estadísticos incluidos nombres de columnas, tipos de datos, y estadísticas descriptivas de campos numéricos.

Inferencia con Inteligencia Artificial Local. El sistema se conecta a un servidor de inferencia local compatible con la API de OpenAI (mediante `llama.cpp`). Esta arquitectura on-premise garantiza que los datos sensibles o el proceso de análisis no dependan de servicios en la nube de terceros, satisfaciendo requisitos de soberanía de datos aplicables a contextos gubernamentales.

El módulo envía un *prompt* de sistema especializado que instruye al modelo de lenguaje para evaluar la viabilidad del conjunto de datos conforme a criterios de ingeniería geotérmica específicos. Estos criterios incluyen la presencia de variables termodinámicas (temperatura, flujo de masa), datos geoquímicos, o indicadores de estabilidad de producción necesarios para proyectos ORC [Alyafeai et al., 2025].

Salida Estructurada Garantizada. En lugar de procesar respuestas textuales de lenguaje natural, el sistema fuerza que la salida de la IA cumpla estrictamente con un esquema `JSON` predefinido. Se utiliza la librería `Instructor` junto con validación `Pydantic` para garantizar que la respuesta incluya obligatoriamente: un booleano de viabilidad ("is_viable"), razonamiento técnico, y un diccionario de variables físicas detectadas. Este enfoque elimina la ambigüedad característica del lenguaje natural y facilita el procesamiento *downstream* [Liu, 2024].

Artefactos de Análisis. Los resultados se guardan en archivo 'metadata_analysis.json' con el esquema previamente validado. Se genera además una descripción legible ('description.md') para validación humana.

2.1.3. Módulo 3: Ingesta y Publicación (*Uploader*)

Este módulo gestiona la interoperabilidad con repositorios externos y la desagregación recursiva de archivos comprimidos para mejorar la accesibilidad.

Filtrado de Publicación. Solo se procede a la carga en el repositorio destino si el archivo de análisis indica "is_viable: true". Esto asegura que el catálogo público contenga únicamente datasets técnicamente relevantes para estudios de ingeniería geotérmica.

Mapeo de Metadatos. El sistema transforma el objeto `JSON` de metadatos al esquema requerido por `CKAN` (Comprehensive Knowledge Archive Network), una plataforma de código abierto ampliamente adoptada en gobiernos para portales de datos abiertos [Wang et al., 2020; Klutch.sh Documentation, 2025].

Manejo Recursivo de Archivos Comprimidos. Al procesar archivos para la subida, el sistema detecta contenedores (ZIP, TAR, GZ). Sube primero el archivo original, luego descomprime temporalmente y sube cada archivo contenido como recurso separado en `CKAN`, mejorando la accesibilidad para ciudadanos que de otro modo tendrían que descargar y descomprimir gigabytes de información.

3. Flujo de Trabajo Integrado

El flujo operativo de SARAD se ejecuta en tres fases distintas, utilizando "carriles" (*swimlanes*) para delimitar responsabilidades de cada subsistema.

3.1. Fase 1: Adquisición y Persistencia

El flujo inicia con iteración secuencial sobre un rango configurable de identificadores de envío. Para cada ID:

1. Se consulta la base de datos local. Si el registro existe y está marcado como "complete", se omite.
2. Se realiza una solicitud HTTP al repositorio remoto. Si la respuesta es exitosa (2xx), se descargan metadatos y archivos.
3. Si el servidor remoto responde con HTTP 404, se registra el evento y se continúa (comportamiento *fail-safe*).
4. Si ocurren errores de conexión, se reintenta hasta 3 veces con espera exponencial.
5. Los archivos descargados se organizan en directorios locales con nomenclatura sanitizada: 'ID_Titulo_Dataset'.

3.2. Fase 2: Filtrado y Enriquecimiento Semántico

Esta fase representa el valor agregado del sistema:

1. **Normalización:** Los archivos comprimidos se expanden en directorios temporales seguros.
2. **Validación de Formato:** Se aplica el filtro determinista. ¿Contiene el envío archivos tabulares viables?
   - Si *No:* El flujo termina, marcado como "*skipped*".
   - Si *Sí:* Se procede a extracción de características.
3. **Evaluación Cognitiva:** Se construye un *prompt* que combina metadatos y resúmenes estadísticos. Este contexto se envía al LLM local.
4. **Decisión de Viabilidad:** Basado en la respuesta `JSON` de la IA:
   - *Viable:* Se generan metadatos enriquecidos (título académico, descripción técnica, variables físicas detectadas).
   - *No Viable:* Se registra la razón del rechazo.

3.3. Fase 3: Ingesta y Publicación

El flujo final asegura que solo datos técnicamente validados y debidamente catalogados se publiquen en el repositorio gubernamental:

1. **Verificación de Integridad:** Se valida que el archivo JSON de análisis indique 'is_viable: true'.
2. **Creación de Paquete:** Se registra el dataset en `CKAN` con metadatos generados por la IA.
3. **Carga Recursiva:** Se itera sobre archivos. Si se encuentran contenedores, se extraen y cargan componentes individuales.
4. **Finalización:** Se marca el envío como "*published*" en la base de datos local.

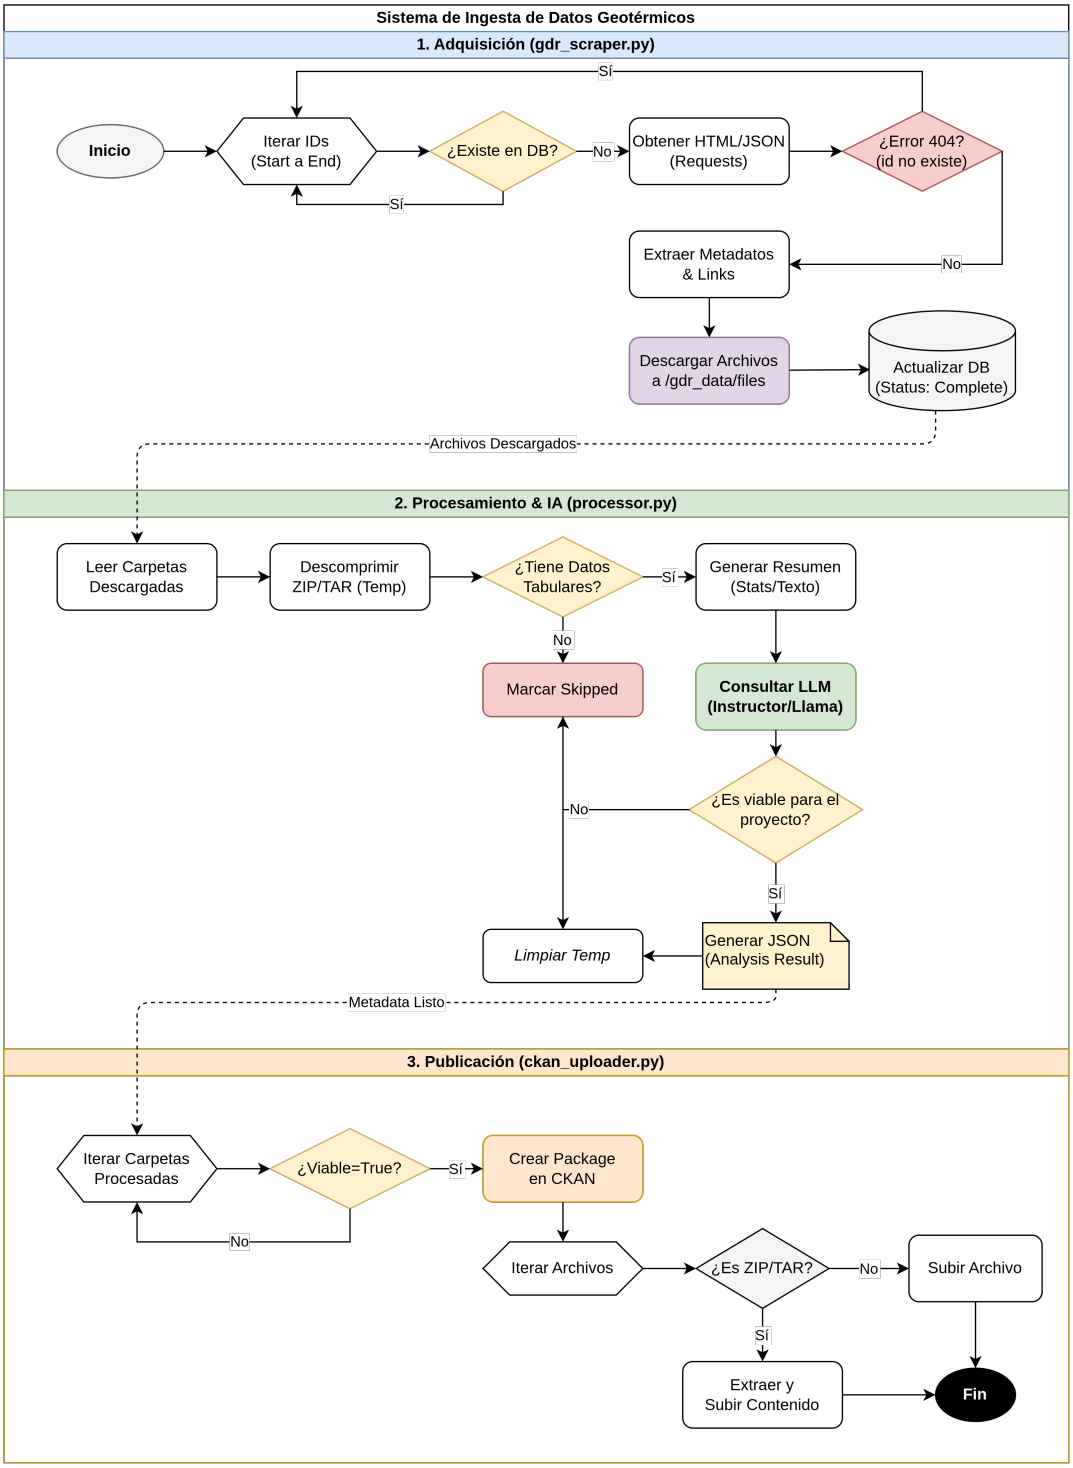

Figura 1: Diagrama de flujo de trabajo integrado de SARAD en tres fases: (1) Adquisición y Persistencia (carril *Scraper*), donde se descargan datos con idempotencia; (2) Filtrado y Enriquecimiento Semántico (carril *Processor*), donde se aplica validación determinista de formato y evaluación cognitiva mediante LLM; (3) Ingesta y Publicación (carril *Uploader*), donde se cargan datasets validados en CKAN con manejo recursivo de archivos comprimidos. Los puntos de decisión determinan el flujo según criterios de viabilidad y disponibilidad de datos tabulares.

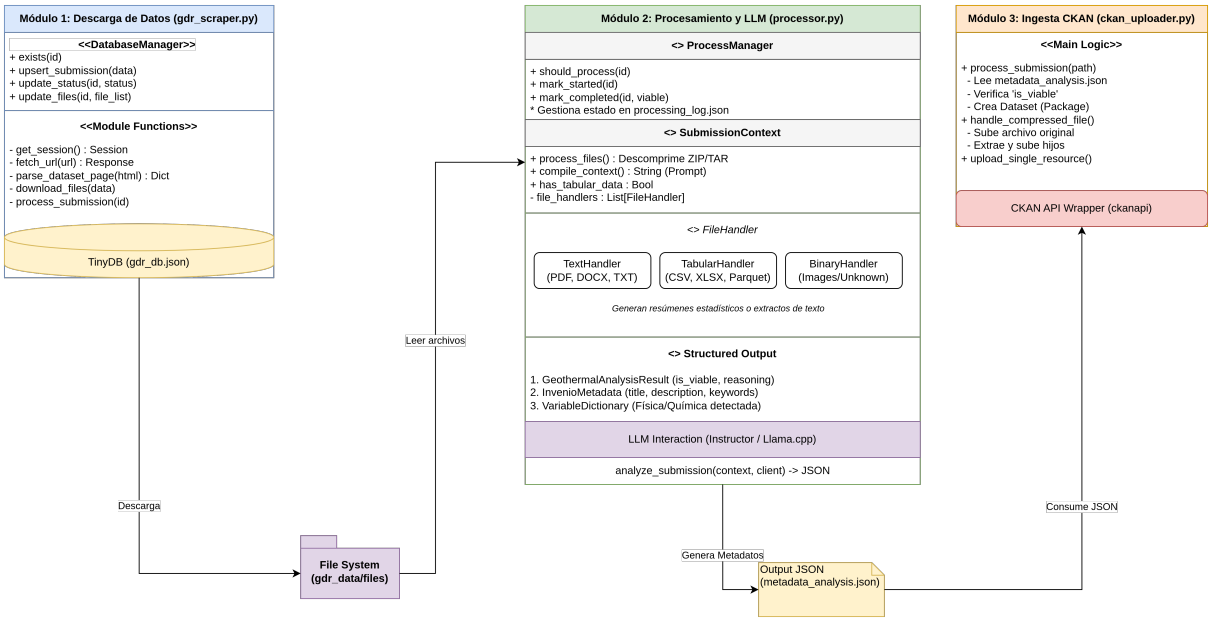

Figura 2: Diagrama de arquitectura de componentes y clases de SARAD mostrando tres módulos funcionales independientes: (1) Módulo 1 (*Scraper*) con `DatabaseManager` para idempotencia y gestión de red; (2) Módulo 2 (*Processor*) con `SubmissionContext`, `FileHandler` polimórfico (`TextHandler`, `TabularHandler`), integración con LLM local, y salida estructurada `Pydantic`; (3) Módulo 3 (*Uploader*) con `CKAN API Wrapper` para interoperabilidad. La comunicación entre módulos se realiza mediante archivos `JSON` persistentes, garantizando bajo acoplamiento.

4. Arquitectura de Componentes de Software

4.1. Módulo 1: DatabaseManager y Network Wrapper

La clase `DatabaseManager` implementa el patrón *Wrapper* sobre `TinyDB`, encapsulando la lógica de persistencia e idempotencia. La clase ‘Network Wrapper‘ encapsula la librería `requests` para manejar reintentos automáticos, *timeouts*, y políticas de “cortesía” (*politeness delay*, con el objetivo de no sobrecargar el servidor público del cual se obtienen los datos) que respetan los términos de servicio del servidor origen.

4.2. Módulo 2: *SubmissionContext* y *FileHandler*

La clase `SubmissionContext` actúa como contenedor que agrega todos los archivos y metadatos de un envío específico, gestionando el ciclo de vida de datos temporales. Se implementa el *patrón Strategy* mediante la clase abstracta `FileHandler`, con especializaciones:

- **TextHandler:** Especializado en extracción de texto de documentos no estructurados (PDF, DOCX).
- **TabularHandler:** Especializado en generación de resúmenes estadísticos de datos estructurados (CSV, XLSX, Parquet).

La integración con el LLM (‘Instructor/llama.cpp‘) no maneja texto libre, sino que impone salidas estructuradas utilizando modelos Pydantic (‘GeothermalAnalysisResult‘). Esto garantiza que la IA devuelva objetos JSON válidos con campos específicos (booleano de viabilidad, razonamiento técnico, variables físicas), eliminando ambigüedad.

4.3. Módulo 3: CKAN API Wrapper

Este módulo utiliza la librería ‘ckanapi‘ para interactuar con el repositorio destino. Implementa lógica recursiva para detectar archivos comprimidos, subir el original, y posteriormente extraer y subir cada componente

individual.

5. Integración de Modelos de Lenguaje Generativo con Validación Semántica

La incorporación de un LLM como motor de validación semántica representa una innovación significativa en la arquitectura. Tradicionalmente, los pipelines de datos ETL (*Extract, Transform, Load*) utilizan validaciones basadas en reglas estáticas (e.g., esquemas de tipo fijo, rangos numéricos). Estas aproximaciones carecen de capacidad para capturar contexto semántico complejo, como la plausibilidad técnica de un conjunto de datos dentro del dominio de la ingeniería geotérmica [Liu, 2025; Alyafeai et al., 2025].

SARAD direcciona esta limitación mediante:

1. **Validación semántica estructurada:** El LLM evalúa la viabilidad del dataset contra criterios expresados en lenguaje natural, pero validados contra un esquema JSON formal. Esta combinación aprovecha la flexibilidad del lenguaje natural sin sacrificar la certeza de máquinas.
2. **Generación de metadatos técnicos:** Más allá de validación binaria, el sistema extrae de forma automática variables físicas clave (temperatura, flujo, propiedades geoquímicas) presentes en el dataset, facilitando indexación y descubrimiento subsecuentes.
3. **Razonamiento transferible:** Cada decisión de viabilidad se acompaña de justificación técnica, permitiendo que analistas humanos cuestionen o refinen los criterios sin necesidad de recodificar el sistema.

6. Garantías de Calidad de Datos

Capa 1: Validación de Esquema. Los datos ingresados cumplen tipos de datos, restricciones de longitud, y formatos de fecha estandarizados.

Capa 2: Validación de Regla de Negocio. Se valida que los envíos contienen variaciones específicas de datos (e.g., archivos tabulares presentes antes de análisis profundo). Se aplican reglas deterministas codificadas en la lógica del procesador.

Capa 3: Validación Semántica. El LLM evalúa coherencia contextual, plausibilidad técnica, y completitud de información respecto a criterios de dominio especializado en geotermia.

Auditoría Completa. Cada etapa de procesamiento se registra en un archivo de `log` con marcas temporales, identificadores de usuario (donde aplique), y descripción de acciones y decisiones. Esto facilita trazabilidad y cumplimiento de requisitos de transparencia en contextos gubernamentales.

7. Manejo de Excepciones y Recuperación ante Fallos

SARAD está diseñado bajo el principio de "continuidad operativa". Cuando ocurren excepciones:

- Se registra el incidente detalladamente en auditoría con contexto completo (stack trace, estado previo).
- El sistema omite el ítem problemático y actualiza su estatus en la base de datos local.
- Continúa inmediatamente con el siguiente ítem en el lote sin pausa manual.
- Al finalizar el lote, genera un reporte de excepciones para revisión posterior.

Esto contrasta con arquitecturas monolíticas tradicionales donde un único error detiene el proceso completo. La recuperación ante interrupciones abruptas (corte de energía, cierre inesperado) es posible gracias a la persistencia de estado en `TinyDB`, permitiendo que el sistema reanude desde el último punto exitoso sin pérdida de datos o reprocessamiento innecesario.

8. Implicaciones para la Transición Energética Nacional

La automatización de la estimación de potencial geotérmico en campos activos de petróleo y gas colombianos ofrece múltiples beneficios estratégicos:

1. **Reducción de Incertidumbre Exploratoria:** La integración sistemática de datos geológicos y de ingeniería disminuye la incertidumbre característica de proyectos geotérmicos iniciales, permitiendo tomas de decisión con mayor confianza.

2. **Aceleración de Decisiones de Inversión:** Los análisis automatizados permiten evaluaciones rápidas de viabilidad para cientos de pozos, facilitando priorización de inversiones y reduciendo ciclos de evaluación de meses a semanas.

3. **Aprovechamiento de Infraestructura Existente:** Al utilizar pozos ya perforados para exploración geotérmica, se minimizan los costos y riesgos asociados a perforación exploratoria, acelerando el retorno de inversión.

4. **Soberanía de Datos:** La ejecución on-premise de análisis de IA y la persistencia de datos en infraestructura local respetan requisitos de privacidad y gobernanza de datos del sector público colombiano, evitando transferencias a servidores externos.

9. Conclusión

SARAD representa una solución técnica madura que prioriza la calidad de datos sobre la cantidad. La arquitectura modular, la integración de validación semántica basada en LLM, y los mecanismos robustos de recuperación ante fallos garantizan que el sistema es apto para operación en contextos de producción y a escala nacional. La publicación de datasets enriquecidos en CKAN facilita el acceso público a información crítica para la toma de decisiones en transición energética, alineándose con objetivos nacionales de sostenibilidad y economía circular.

La viabilidad técnica de SARAD ha sido demostrada a través del análisis riguroso de su arquitectura modular, la justificación de cada decisión de diseño basada en principios de ingeniería de software establecidos, y la integración de tecnologías contemporáneas (LLM, validación semántica, CKAN). Los desafíos de implementación son conocidos y abordables mediante recursos estándar en la industria de desarrollo de software.

10. Visualización y Acceso a Datos en la Plataforma CKAN

Una vez completadas las fases de adquisición, validación semántica e ingesta, los datos procesados por SARAD residen en la instancia local de CKAN. Esta plataforma actúa como la interfaz final para el usuario (investigadores, ingenieros y tomadores de decisiones), proporcionando un catálogo centralizado, buscable y estandarizado. A continuación, se describe la experiencia de usuario y la estructura de la información tal como se presenta en el repositorio, utilizando como caso de estudio un conjunto de datos real procesado por el sistema.

10.1. Búsqueda y Descubrimiento de Datasets

La interfaz principal de CKAN permite el descubrimiento de información mediante búsquedas por palabras clave y filtrado facetado (por etiquetas o formatos). Como se observa en la Figura 3, el sistema ha indexado exitosamente los envíos procesados.

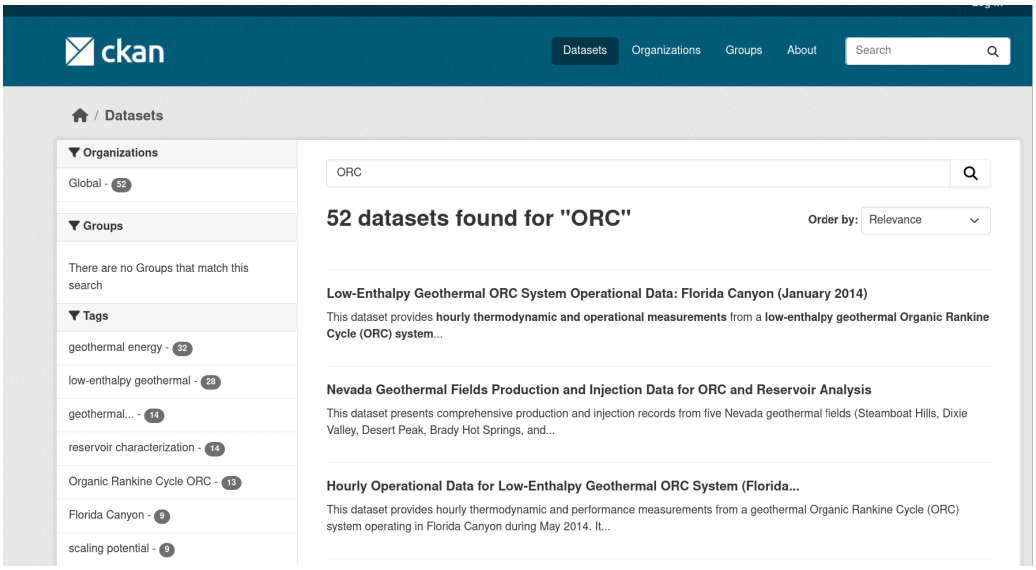

Figura 3: Interfaz de búsqueda de CKAN mostrando los resultados para el término “ORC”. Se observan 52 datasets identificados y catalogados, con filtros laterales para categorías como “geothermal energy” y “low-enthalpy geothermal”.

En este ejemplo, la búsqueda del término “ORC” (Organic Rankine Cycle) recupera 52 conjuntos de datos relevantes. La consistencia en el etiquetado, generada parcialmente durante la etapa de procesamiento de metadatos, permite agrupar datasets bajo categorías temáticas coherentes como *low-enthalpy geothermal* o *reservoir characterization*.

10.2. Metadatos Enriquecidos y Variables Identificadas

Al seleccionar un conjunto de datos específico, el usuario accede a la vista de detalles. Esta vista es el resultado directo del enriquecimiento semántico realizado por el Módulo 2 (Processor) de SARAD. A diferencia de un repositorio de archivos estático, CKAN presenta metadatos estructurados que describen el contenido técnico del recurso.

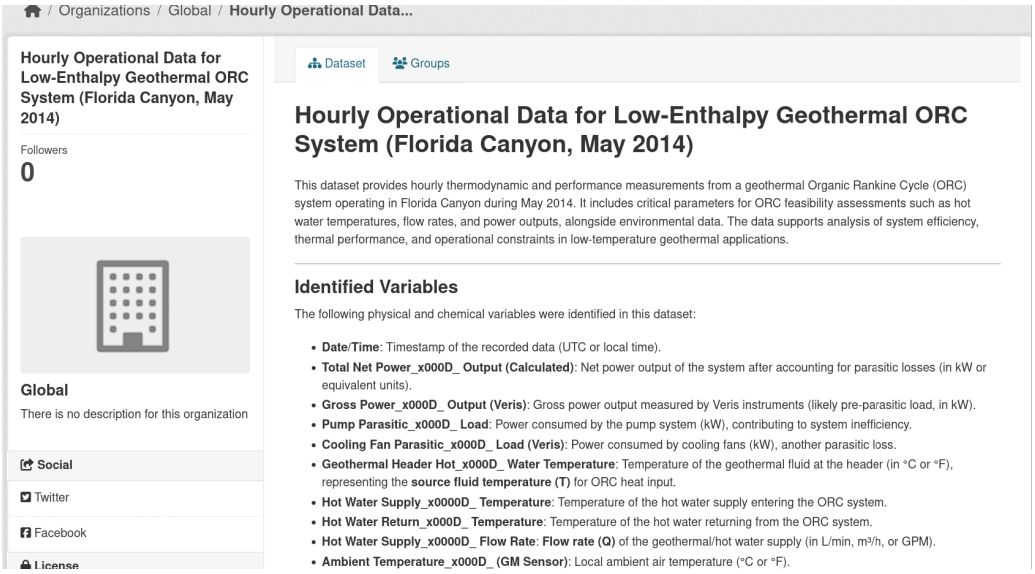

Figura 4: Vista detallada de un dataset específico (Florida Canyon, May 2014). Se destaca la sección "Identified Variables", donde se listan los parámetros físicos (potencia neta, carga parásita, temperaturas de suministro y retorno) extraídos automáticamente por el análisis del LLM.

La Figura 4 muestra cómo la descripción generada por la Inteligencia Artificial se integra en el campo de descripción del dataset. Crucialmente, se observa la sección de variables físicas identificadas (*Identified Variables*), que detalla parámetros críticos para la ingeniería geotérmica como "Total Net Power Output", "Geothermal Header Temperature" y tasas de flujo. Esta información permite al investigador evaluar la utilidad del dataset sin necesidad de descargar y abrir los archivos, optimizando el proceso de revisión literaria.

10.3. Gestión de Recursos y Proveniencia

La sección inferior de la ficha del dataset gestiona los archivos físicos y la información de contexto (Figura 5). SARAD se encarga de subir tanto los datos crudos (en formatos abiertos como XLSX o CSV) como los archivos de metadatos auxiliares (por ejemplo, citas en formato BibTeX).

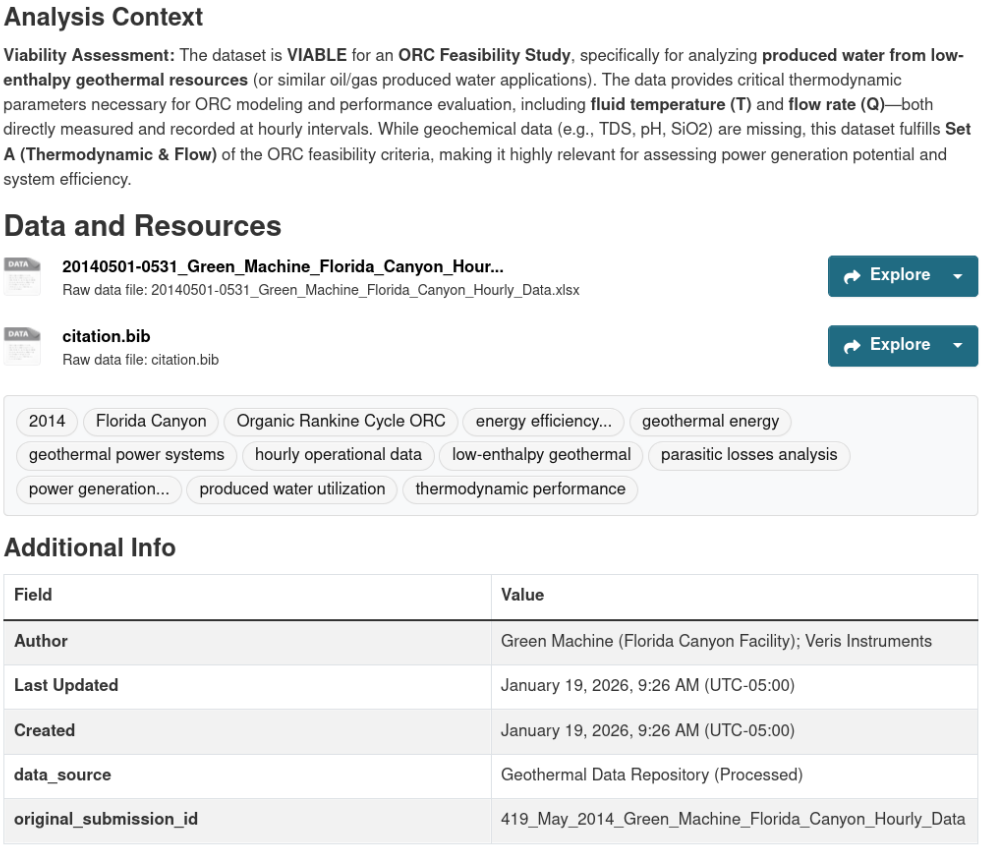

Analysis Context

Viability Assessment: The dataset is **VIABLE** for an **ORC Feasibility Study**, specifically for analyzing **produced water from low-enthalpy geothermal resources** (or similar oil/gas produced water applications). The data provides critical thermodynamic parameters necessary for ORC modeling and performance evaluation, including **fluid temperature (T)** and **flow rate (Q)**—both directly measured and recorded at hourly intervals. While geochemical data (e.g., TDS, pH, SiO2) are missing, this dataset fulfills **Set A (Thermodynamic & Flow)** of the ORC feasibility criteria, making it highly relevant for assessing power generation potential and system efficiency.

Data and Resources

20140501-0531_Green_Machine_Florida_Canyon_Hour...
Raw data file: 20140501-0531_Green_Machine_Florida_Canyon_Hourly_Data.xlsx
Explore

citation.bib
Raw data file: citation.bib
Explore

2014 | Florida Canyon | Organic Rankine Cycle ORC | energy efficiency... | geothermal energy | geothermal power systems | hourly operational data | low-enthalpy geothermal | parasitic losses analysis | power generation... | produced water utilization | thermodynamic performance

Additional Info

Field	Value
Author	Green Machine (Florida Canyon Facility); Veris Instruments
Last Updated	January 19, 2026, 9:26 AM (UTC-05:00)
Created	January 19, 2026, 9:26 AM (UTC-05:00)
data_source	Geothermal Data Repository (Processed)
original_submission_id	419_May_2014_Green_Machine_Florida_Canyon_Hourly_Data

Figura 5: Sección de recursos y metadatos adicionales. Se observan los archivos disponibles para descarga (datos crudos y citas bibliográficas) y la tabla de metadatos administrativos que incluye autoría, fecha de última actualización y el identificador de la sumisión original.

Además, se preserva la trazabilidad del dato mediante campos como ‘original_submission_id‘ y ‘data_source‘. La inclusión del contexto de análisis (*Analysis Context*) informa al usuario sobre la evaluación de viabilidad realizada por el sistema, indicando explícitamente que el dataset es “VIABLE” para estudios de factibilidad ORC debido a la presencia de datos termodinámicos y de flujo.

10.4. Verificación y Consumo del Dato Tabular

El objetivo final del sistema SARAD es poner a disposición datos estructurados y listos para el análisis. La Figura 6 demuestra el resultado final del flujo de trabajo: el usuario descarga el recurso principal y lo visualiza en una aplicación de hoja de cálculo.

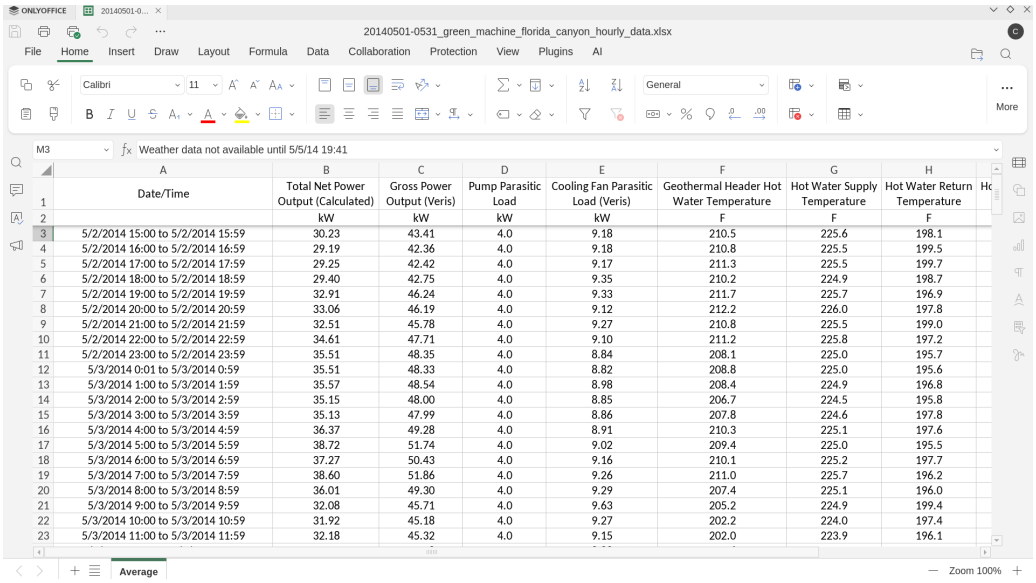

20140501-0531_green_machine_florida_canyon_hourly_data.xlsx

M3 Weather data not available until 5/5/14 19:41

	A	B	C	D	E	F	G	H
1	Date/Time	Total Net Power Output (Calculated)	Gross Power Output (Veris)	Pump Parasitic Load	Cooling Fan Parasitic Load (Veris)	Geothermal Header Hot Water Temperature	Hot Water Supply Temperature	Hot Water Return Temperature
2		kW	kW	kW	kW	F	F	F
3	5/2/2014 15:00 to 5/2/2014 15:59	30.23	43.41	4.0	9.18	210.5	225.6	198.1
4	5/2/2014 16:00 to 5/2/2014 16:59	29.19	42.36	4.0	9.18	210.8	225.5	199.5
5	5/2/2014 17:00 to 5/2/2014 17:59	29.25	42.42	4.0	9.17	211.3	225.5	199.7
6	5/2/2014 18:00 to 5/2/2014 18:59	29.40	42.75	4.0	9.35	210.2	224.9	198.7
7	5/2/2014 19:00 to 5/2/2014 19:59	32.91	46.24	4.0	9.33	211.7	225.7	196.9
8	5/2/2014 20:00 to 5/2/2014 20:59	33.06	46.19	4.0	9.12	212.2	226.0	197.8
9	5/2/2014 21:00 to 5/2/2014 21:59	32.51	45.78	4.0	9.27	210.8	225.5	199.0
10	5/2/2014 22:00 to 5/2/2014 22:59	34.61	47.71	4.0	9.10	211.2	225.8	197.2
11	5/2/2014 23:00 to 5/2/2014 23:59	35.51	48.35	4.0	8.84	208.1	225.0	195.7
12	5/3/2014 0:01 to 5/3/2014 0:59	35.51	48.33	4.0	8.82	208.8	225.0	195.6
13	5/3/2014 1:00 to 5/3/2014 1:59	35.57	48.54	4.0	8.98	208.4	224.9	196.8
14	5/3/2014 2:00 to 5/3/2014 2:59	35.15	48.00	4.0	8.85	206.7	224.5	195.8
15	5/3/2014 3:00 to 5/3/2014 3:59	35.13	47.99	4.0	8.86	207.8	224.6	197.8
16	5/3/2014 4:00 to 5/3/2014 4:59	36.37	49.28	4.0	8.91	210.3	225.1	197.6
17	5/3/2014 5:00 to 5/3/2014 5:59	38.72	51.74	4.0	9.02	209.4	225.0	195.5
18	5/3/2014 6:00 to 5/3/2014 6:59	37.27	50.43	4.0	9.16	210.1	225.2	197.7
19	5/3/2014 7:00 to 5/3/2014 7:59	38.60	51.86	4.0	9.26	211.0	225.7	196.2
20	5/3/2014 8:00 to 5/3/2014 8:59	36.01	49.30	4.0	9.29	207.4	225.1	196.0
21	5/3/2014 9:00 to 5/3/2014 9:59	32.08	45.71	4.0	9.63	205.2	224.9	199.4
22	5/3/2014 10:00 to 5/3/2014 10:59	31.92	45.18	4.0	9.27	202.2	224.0	197.4
23	5/3/2014 11:00 to 5/3/2014 11:59	32.18	45.32	4.0	9.15	202.0	223.9	196.1

Figura 6: Archivo de datos descargado desde CKAN y abierto en una aplicación de hoja de cálculo. Se verifica la estructura tabular limpia con columnas correspondientes a las variables identificadas en los metadatos (Fecha/Hora, Potencia Neta, Temperaturas, etc.), demostrando la integridad del dato tras el proceso de ingesta.

El archivo abierto revela una serie de tiempo horaria con mediciones precisas de operación del sistema ORC. La correspondencia exacta entre las columnas del archivo Excel (Columna B: *Total Net Power*, Columna F: *Geothermal Header Temperature*) y los metadatos mostrados en la interfaz web valida la precisión del módulo de extracción de características. El investigador dispone así de un archivo limpio, validado y documentado, listo para ser ingestado en modelos de simulación numérica o herramientas de análisis estadístico.

10.5. Base de datos SQL

Paralelamente se implementó un ducto de datos (*pipeline*) para transformar los activos de información heterogéneos (archivos planos, hojas de cálculo) en una estructura relacional SQL. Esta fase del sistema aborda el desafío de la dispersión de datos mediante la centralización en un motor de base de datos relacional con extensiones geoespaciales, garantizando integridad, trazabilidad y capacidad de consulta analítica compleja.

La arquitectura de persistencia se diseñó bajo un modelo jerárquico de tres niveles que separa los metadatos administrativos de los datos científicos brutos, permitiendo una gestión eficiente del almacenamiento y la recuperación.

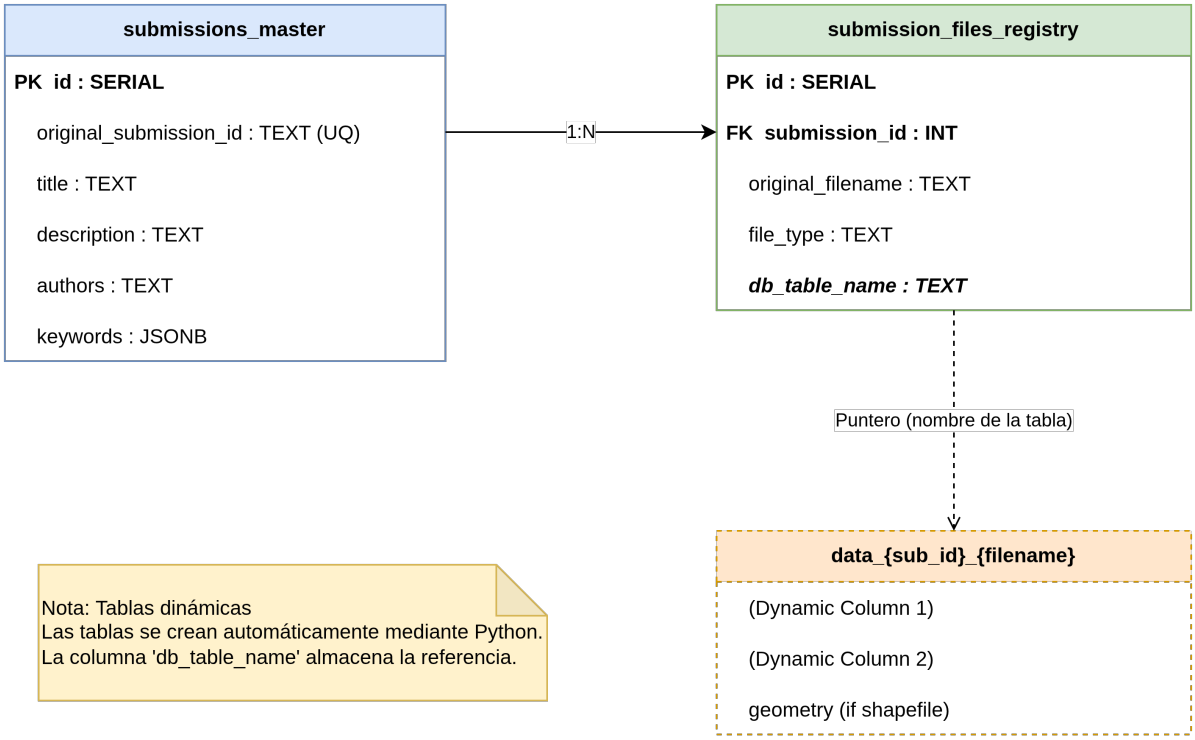

Figura 7: Esquema de la base de datos relacional implementada. Se observa la relación 1:N entre la tabla maestra de envíos (‘submissions_master‘) y el registro de archivos (‘submission_files_registry‘). Las líneas discontinuas ilustran el mecanismo de puntero lógico hacia tablas dinámicas (‘data_{sub_id}_{filename}‘), generadas automáticamente durante la ingesta para almacenar datos crudos y geometrías espaciales.

El proceso de estructuración se ejecuta mediante un algoritmo de procesamiento por lotes que sigue una metodología estricta de normalización:

1. **Nivel de Gestión (Metadatos):** Se consolida la información bibliográfica (título, autores, descripción) en la tabla ‘submissions_master‘. Este índice maestro permite búsquedas rápidas sin necesidad de acceder a los volúmenes masivos de datos crudos.

2. **Inventario y Registro:** La tabla ‘submission_files_registry‘ actúa como un mapa de inventario, vinculando cada metadato con los archivos físicos asociados. Aquí se registran los tipos de archivo inferidos y se preserva la relación de pertenencia.

3. **Ingesta Dinámica y Sanitización:** Para cada archivo de datos válido (CSV, Excel, Shapefile), el sistema aplica reglas de sanitización a los nombres de columnas (eliminación de caracteres especiales, estandarización a minúsculas) y crea dinámicamente una tabla independiente en la base de datos. Como se ilustra en la Figura 7, el nombre de esta tabla se construye algorítmicamente vinculando el ID del envío y el nombre del archivo original, asegurando unicidad.

11. Revisión sistemática automatica

El sistema identifica, identifica bases datos en artículos científicos relevantes, transformándolas en información estructurada y reutilizable. Este proceso permite recuperar datos valiosos que frecuentemente quedan atrapados en formatos no estructurados como documentos PDF, facilitando su análisis posterior y su integración en repositorios centralizados.

11.1. Propósito general

Los artículos científicos contienen grandes volúmenes de datos empíricos, experimentales y observacionales que representan un recurso valioso para la investigación [Team and Khan, 2025; Belcic and Stryker, 2025]. Sin embargo, estos datos suelen encontrarse en formatos semiestructurados o no estructurados que dificultan su recuperación y reutilización sistemática. El objetivo del sistema es automatizar la extracción de estas bases de datos desde documentos científicos, transformarlas en formatos consultables y consolidarlas en un repositorio central que facilite el acceso y la trazabilidad.

11.2. Identificación de fuentes y extracción

El proceso inicia con la identificación de artículos científicos relevantes que contienen bases de datos, tablas de mediciones, conjuntos de variables experimentales o resultados cuantitativos [Team and Khan, 2025; Automation Anywhere, 2025]. Una vez identificados los documentos, el sistema convierte los PDF en texto enriquecido que preserva la estructura del documento original—incluyendo tablas, fórmulas matemáticas y descripciones de figuras—utilizando modelos especializados en comprensión documental [Livathinos et al., 2025].

Esta conversión es fundamental porque permite que los algoritmos de extracción identifiquen con precisión los elementos relevantes sin perder el contexto científico. La extracción de datos desde documentos no estructurados requiere técnicas avanzadas que combinan análisis sintáctico, reconocimiento de patrones y comprensión del lenguaje natural [Belcic and Stryker, 2025; Automation Anywhere, 2025].

11.3. Análisis asistido por inteligencia artificial

Tras la conversión, el sistema emplea inteligencia artificial para analizar el contenido científico en dos etapas. Primero, se identifican y extraen las secciones que contienen información estructurable: definiciones de variables, unidades de medida, ecuaciones físicas, parámetros experimentales, conjuntos de datos y metadatos asociados. Esta extracción se guía mediante instrucciones especializadas que orientan al modelo sobre qué información buscar y cómo organizarla [Belcic and Stryker, 2025].

En la segunda etapa, el sistema estructura la información extraída en un formato estandarizado (JSON) con campos definidos que incluyen información bibliográfica, descripción del problema abordado, variables medidas y calculadas, roles de cada variable, supuestos metodológicos y notas sobre aplicabilidad de los resultados. Este formato estructurado es validado automáticamente para garantizar consistencia y completitud.

11.4. Consolidación en repositorio centralizado

Cuando se procesan múltiples artículos científicos, sus bases de datos extraídas deben consolidarse en una estructura unificada que permita consultas comparativas y análisis cruzados [Schmidt et al., 2025; Park et al., 2025]. Para lograrlo, el sistema aplana estructuras jerárquicas complejas en tablas relacionales donde cada fila representa un artículo procesado y cada columna contiene un campo específico de información extraída.

Las listas de elementos (por ejemplo, conjuntos de variables o parámetros) se convierten en celdas de tabla siguiendo políticas configurables: pueden almacenarse como texto JSON para preservar toda la estructura, unirse con separadores para facilitar la lectura humana, o contarse para análisis cuantitativos rápidos. El resultado es una base de datos tabular que puede exportarse a formatos estándar como excel o SQL.

11.5. Trazabilidad y reproducibilidad

Cada documento procesado genera registros intermedios que incluyen el PDF original, su versión en texto enriquecido, el análisis preliminar y la salida final estructurada. Esta trazabilidad completa permite auditar el proceso de extracción, verificar la precisión de los datos recuperados y reproducir resultados cuando sea necesario [Galli et al., 2025].

Además, el sistema incluye mecanismos de caché que evitan reprocesar documentos ya analizados, optimizando el uso de recursos computacionales. La columna de origen en las tablas consolidadas mantiene la referencia

al artículo científico del cual proviene cada fila de datos, facilitando la citación apropiada y el retorno a las fuentes primarias cuando se requiera validación adicional.

11.6. Aplicabilidad al dominio geológico

En el contexto específico del repositorio de datos geológicos, este sistema permite extraer bases de datos sobre propiedades termofísicas de rocas, parámetros de yacimientos geotérmicos, mediciones de gradientes térmicos, composiciones químicas de fluidos, historiales de producción de pozos y resultados de modelaciones numéricas que se encuentran dispersos en la literatura científica [Ahluwalia and Wani, 2024]. La consolidación de estos datos en un repositorio central facilita meta-análisis, calibración de modelos físicos y toma de decisiones informadas para proyectos de energía geotérmica.

Referencias

Ahluwalia, A. and Wani, S. (2024). Leveraging large language models for web scraping.

Alyafeai, Z., Al-Shaibani, M. S., and Ghanem, B. (2025). Mole: Metadata extraction and validation in scientific papers using llms.

Automation Anywhere (2025). What is data extraction? https://www.automationanywhere.com/rpa/data-extraction. Accessed: 2025-12-03.

Belcic, I. and Stryker, C. (2025). What is information extraction? https://www.ibm.com/think/topics/information-extraction. Accessed: 2025-12-03.

Chu, D. (2024). How to ensure modularity and reusability in data pipelines. https://www.secoda.co/blog/how-to-ensure-modularity-and-reusability-in-data-pipelines. Secoda Blog.

Cuello, C. (2024). Data pipeline architecture: Key components & best practices. Accessed: 2026-01-26.

Galli, C., Gavrilova, A. V., and Calciolari, E. (2025). Large language models in systematic review screening: Opportunities, challenges, and methodological considerations. *Information*, 16(5).

Gupta, U. (2025). Why web scraping works in testing but fails in production. Accessed: 2026-01-25.

Klutch.sh Documentation (2025). Deploying a ckan data portal. https://docs.klutch.sh/guides/open-source-software/ckan/. Accessed: 2026-01-26.

Liu, J. (2024). Semantic validation with llms. https://python.useinstructor.com/concepts/semantic_validation/. Instructor documentation, accessed 2026-01-26.

Liu, J. (2025). Understanding semantic validation with structured outputs. https://python.useinstructor.com/blog/2025/05/20/understanding-semantic-validation-with-structured-outputs/. 6 min read; in *Validation*, *Pydantic*, *LLMs* categories on the Instructor blog.

Livathinos, N., Auer, C., Lysak, M., Nassar, A., Dolfi, M., Vagenas, P., Ramis, C. B., Omenetti, M., Dinkla, K., Kim, Y., Gupta, S., de Lima, R. T., Weber, V., Morin, L., Meijer, I., Kuropiatnyk, V., and Staar, P. W. J. (2025). Docling: An efficient open-source toolkit for ai-driven document conversion.

Maddali, R. (2021). Automating data quality assurance using machine learning in etl pipelines. *International Journal of Leading Research Publication*, 2(6).

Park, H., Lee, S., Gim, G., Kim, Y., Kim, D., and Park, C. (2025). Dataverse: Open-source etl (extract, transform, load) pipeline for large language models.

Schmidt, L., Hair, K., Graziosi, S., Campbell, F., Kapp, C., Khanteymoori, A., Craig, D., Engelbert, M., and Thomas, J. (2025). Exploring the use of a large language model for data extraction in systematic reviews: a rapid feasibility study.

Team, A. A. and Khan, R. A. (2025). What is data extraction? definition, how it works, and techniques. Accessed: 2025-12-03.

Wang, Z., Lin, G., Tan, H., Chen, Q., and Liu, X. (2020). Ckan: Collaborative knowledge-aware attentive network for recommender systems. In *Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval*, SIGIR '20, page 219–228, New York, NY, USA. Association for Computing Machinery.

Yudin, A. (2025). Web scraping infrastructure: The foundation that powers real-time data systems. Accessed: 2026-01-26.